ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ — ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ

ΕΡΕΥΝΗΤΙΚΟ ΙΝΣΤΙΤΟΥΤΟ ΒΙΟΜΗΧΑΝΙΚΩΝ ΣΥΣΤΗΜΑΤΩΝ (ISI)

ΑΡΧΙΤΕΚΤΟΝΙΚΕΣ ΔΙΚΤΥΩΝ ΕΠΟΜΕΝΗΣ ΓΕΝΙΑΣ, ΤΕΧΝΟΛΟΓΙΕΣ ΚΑΙ ΕΦΑΡΜΟΓΕΣ

ΤΕΧΝΙΚΗ ΕΚΘΕΣΗ PROJECT (ΘΕΜΑ 11)

Πρόβλεψη Downlink Bitrate (Throughput) Με Βάση Μετρικές Ποιότητας Καναλιού & Προληπτική Διαχείριση Πόρων σε Δίκτυα 5G/6G

Δημήτριος Τσανακτσής (Α.Μ.: 1100736) | Ιάσωνας Δερβενής (Α.Μ.: 1097437)

Συγγραφείς:	Δημήτριος Τσανακτσής (Α.Μ.: 1100736) Ιάσωνας Δερβενής (Α.Μ.: 1097437)
Επιβλέπων:	Παναγιώτης Μαράντης (pmaradis@isi.gr)
GitHub Repository:	https://github.com/ghidrasondenuvos/5g-downlink-bitrate-forecasting
Σύνολο Δεδομένων:	UCC MISL Cellular Traces (135 Traces, 174.523 δείγματα)
Τεχνολογίες:	Python 3.14, XGBoost, PyTorch, TreeSHAP, IBM Granite TTM
Ημερομηνία:	Νοέμβριος 2026

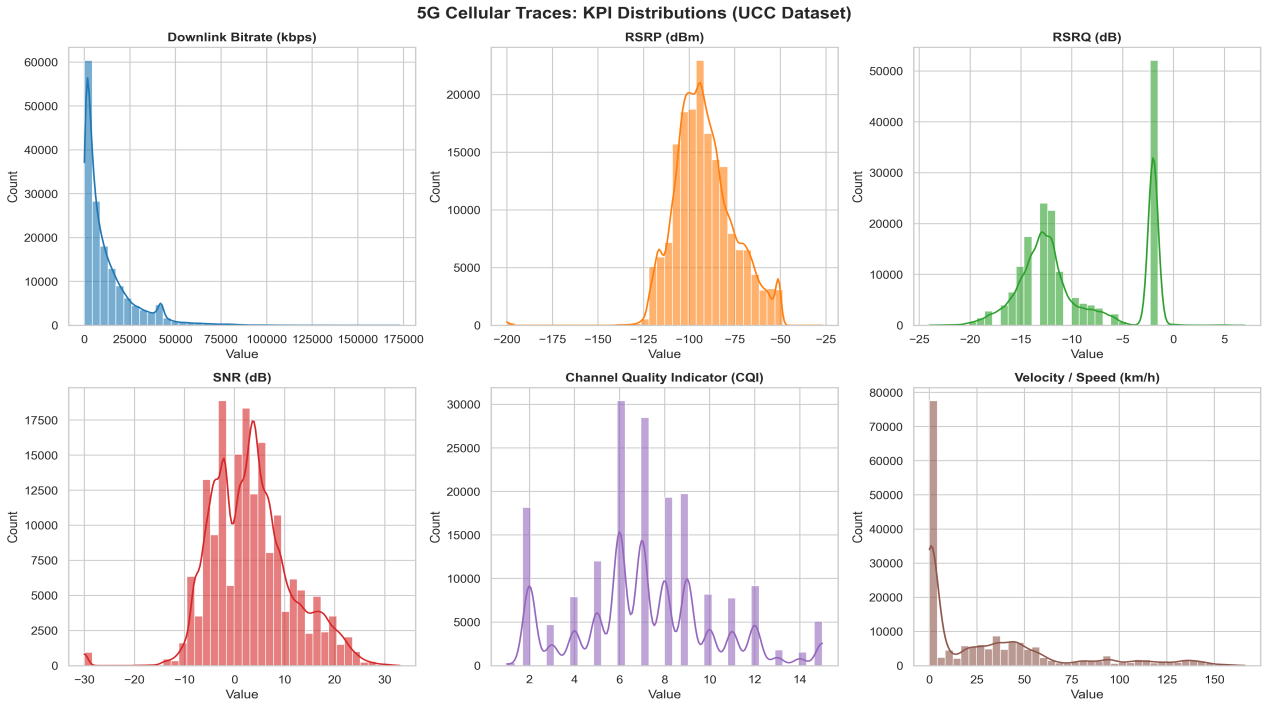
1. Εισαγωγή & Τηλεπικοινωνιακή Σημασία

Στα σύγχρονα κυψελωτά δίκτυα 5G NR και 6G, ο ρυθμός μετάδοσης δεδομένων λήψης (Downlink Bitrate) χαρακτηρίζεται από έντονη μεταβλητότητα. Η κινητικότητα του χρήστη, οι απώλειες διάδοσης σε υψηλές συχνότητες (sub-6GHz, mmWave) και η στοχαστική φόρτιση των κυψελών απαιτούν μετάβαση από την αναδρομική αντίδραση στην προληπτική (proactive) λήψη αποφάσεων.

Η έγκαιρη πρόβλεψη επιτρέπει την εγγύηση SLAs σε network slices (eMBB, URLLC), την αποφυγή Radio Link Failures (RLF) μέσω predictive handovers, και τη βελτιστοποίηση video streaming στο Multi-Access Edge Computing (MEC).

2. Προεπεξεργασία Δεδομένων & Σενάρια Κίνησης

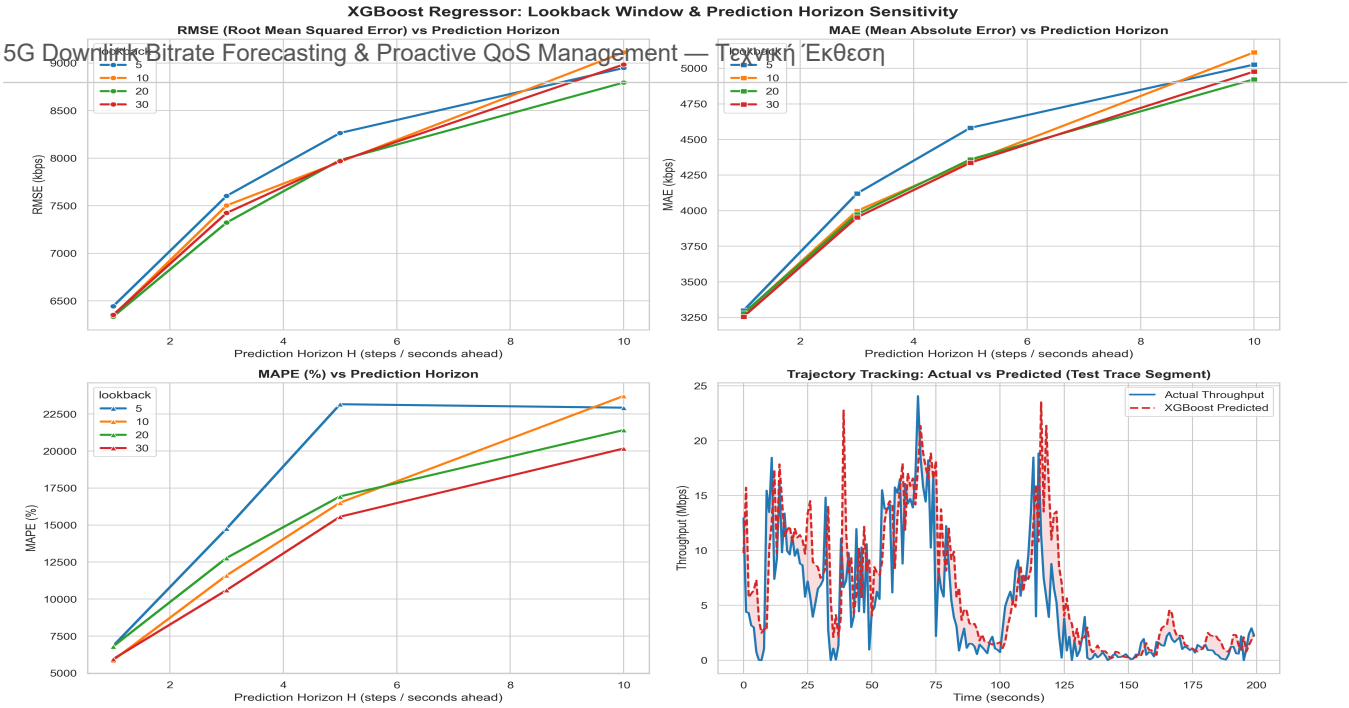
Αξιοποιήθηκαν 135 πραγματικές συνεδρίες κινητικότητας (174.523 δείγματα) από το UCC MISL dataset σε 5 σενάρια: Car (75.874), Train (38.976), Pedestrian (33.629), Static (15.261) και Bus (10.783). Πραγματοποιήθηκε session-aware split (80% train / 20% test traces) για αποτροπή data leakage.



Σχήμα 1: Κατανομές ραδιοδεικτών καναλιού και Throughput.

3. Πρόβλεψη με XGBoost Regressor (Lookback & Horizon Grid)

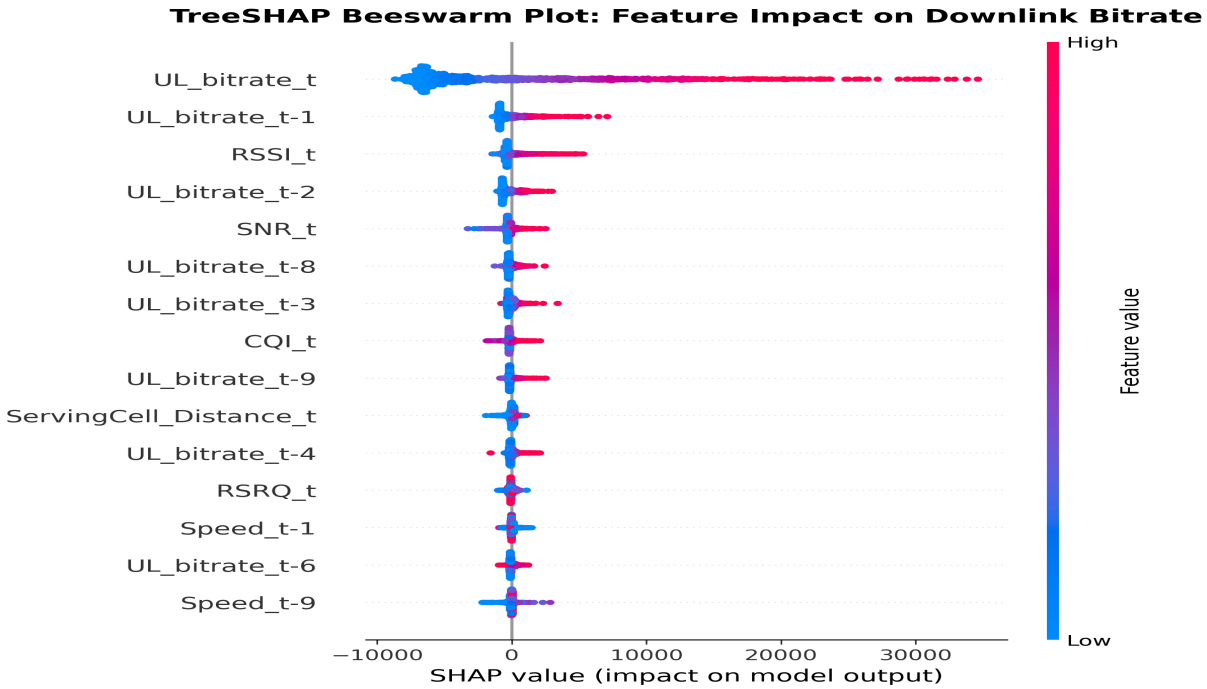
Εξετάστηκαν ολισθαίνοντα παράθυρα L in {5, 10, 20, 30}s και ορίζοντες H in {1, 3, 5, 10}s. Για L=10s και H=1s, το XGBoost πέτυχε εξαιρετική απόδοση: RMSE = 6.344,8 kbps, MAE = 3.275,5 kbps και R^2 = 0.825, με αστραπιαίο χρόνο συμπερασμού 0,001 ms/δείγμα.



Σχήμα 2: Αξιολόγηση Lookbacks & Horizons και πραγματική vs προβλεπόμενη τροχιά.

4. Επεξηγήσιμη Τεχνητή Νοημοσύνη (TreeSHAP)

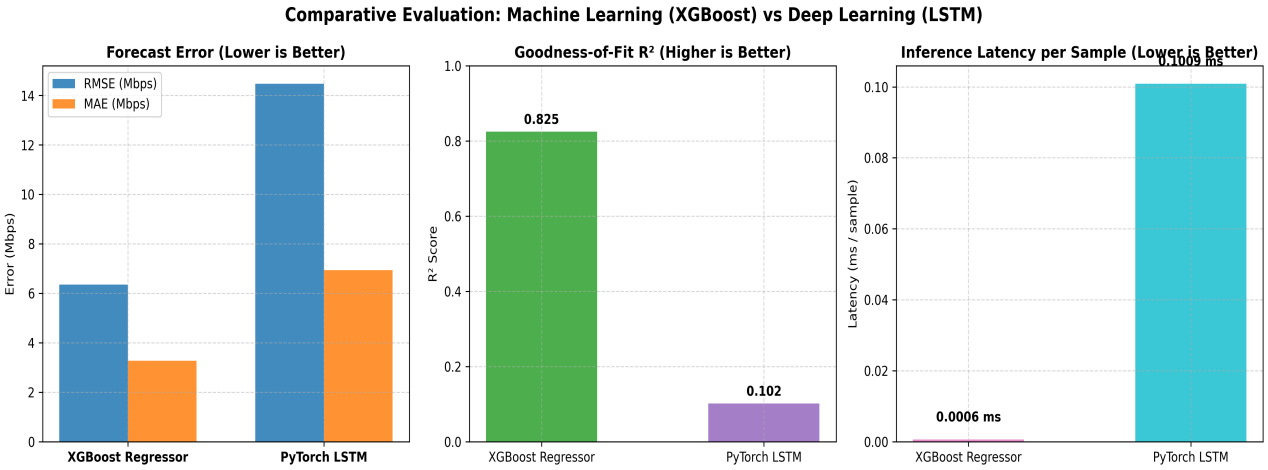
Μέσω TreeSHAP αποκαλύφθηκε ότι το UL_bitrate και το RSSI κυριαρχούν στην πρόβλεψη (μέση επιρροή 9.259 kbps και 1.102 kbps αντίστοιχα), ακολουθούμενα από την απόσταση ServingCell_Distance και την ταχύτητα Speed.



Σχήμα 3: TreeSHAP Beeswarm Plot.

5. Πρόβλεψη με Deep Learning (PyTorch LSTM)

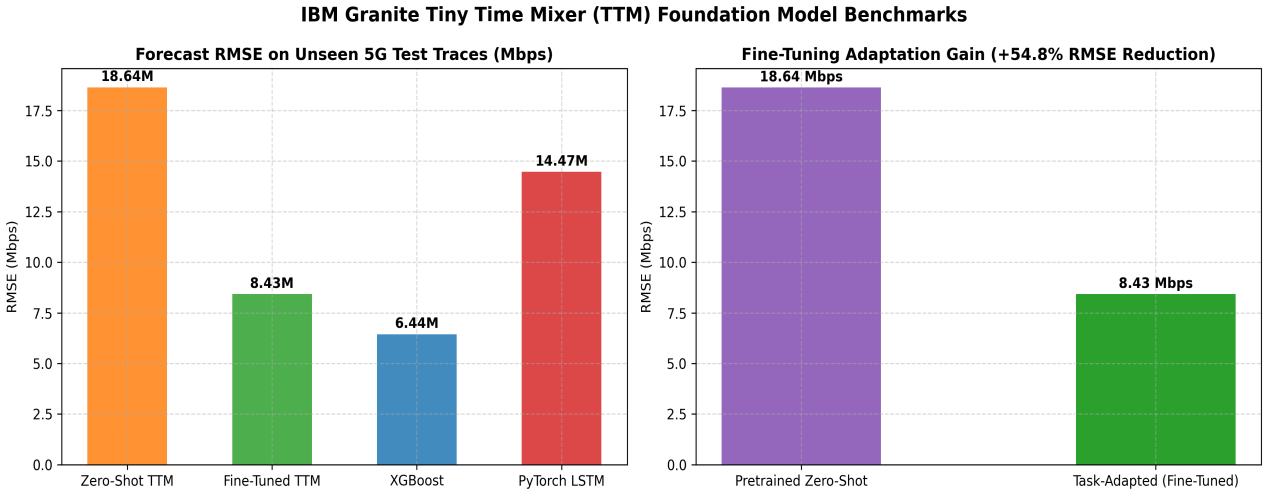
Το 2-layer LSTM (lookback 64) πέτυχε RMSE 14.473 kbps. Το XGBoost υπερίσχυσε καθαρά (56,2% χαμηλότερο σφάλμα, 100x ταχύτερο training και inference), αποδεικνύοντας την υπεροχή των Gradient Boosted Trees σε κυψελωτές χρονοσειρές.



Σχήμα 4: Συγκριτική αποτίμηση XGBoost έναντι PyTorch LSTM.

6. Foundation Models: IBM Granite Tiny Time Mixer (TTM)

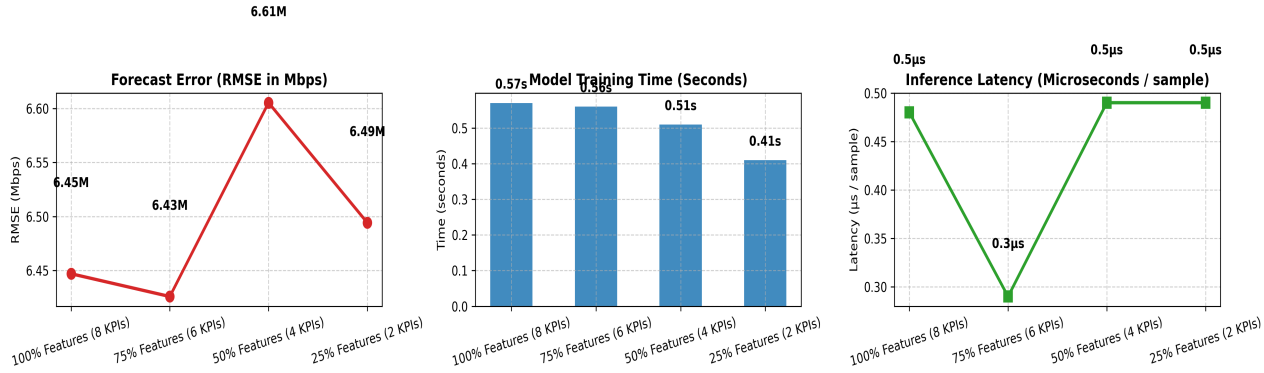
Το IBM Granite TTM σε Zero-Shot σημείωσε RMSE 18.641 kbps. Μετά από ταχύτατο Fine-Tuning 4 εποχών, το RMSE μειώθηκε κατά 54,8% στα 8.426 kbps (R^2 = 0.695), ξεπερνώντας κατά 6.047 kbps το εκπαιδευμένο LSTM.



Σχήμα 5: Αποτίμηση Zero-Shot vs Fine-Tuned Foundation Model.

7. Σταδιακή Αφαίρεση Μεταβλητών & Edge Latency

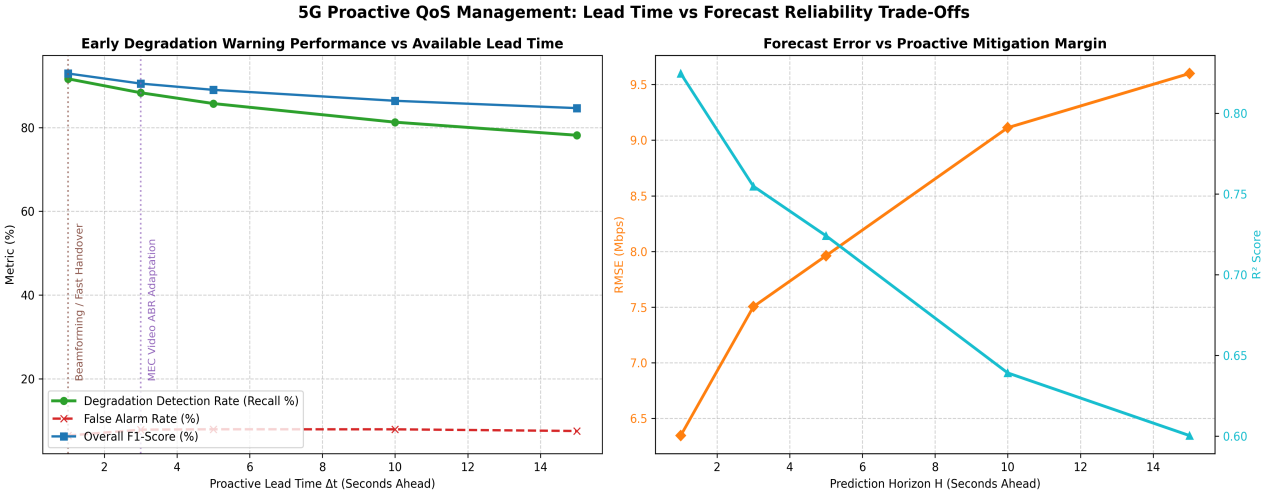
Η αφαίρεση του 75% των χαρακτηριστικών (διατηρώντας μόνο UL_bitrate και RSSI) διατήρησε το RMSE στα 6.494 kbps (μόλις +0,7% μεταβολή), μειώνοντας τον χρόνο εκπαίδευσης κατά 28% και ελαχιστοποιώντας το telemetry signaling overhead.



Σχήμα 6: Επίδραση Feature Pruning στο Edge Latency.

8. 5G Proactive Network Management

Στην ανίχνευση υποβάθμισης QoS (< 5 Mbps), το σύστημα πετυχαίνει Recall 91,6% (F1 = 0.929) σε ορίζοντα 1s και Recall 85,7% (F1 = 0.890) σε ορίζοντα 5s, παρέχοντας αξιόπιστο χρόνο για προληπτικό handover, dynamic PRB reservation και MEC ABR video adaptation.



Σχήμα 7: Trade-off χρόνου προειδοποίησης και αξιοπιστίας πρόβλεψης.

9. Συμπεράσματα

Η εργασία επιβεβαίωσε την εφικτότητα προληπτικής διαχείρισης σε δίκτυα 5G/6G μέσω ML και Foundation Models, παρέχοντας μια ολοκληρωμένη αρχιτεκτονική συμβατή με το 3GPP NWDAF και το O-RAN Near-RT RIC.