Εισαγωγή – Γενικές Οδηγίες

Όλα τα θέματα project απαιτούν υλοποίηση. Η υλοποίηση περιγράφεται σε κάθε θέμα, και κατά κανόνα αφορά **γλώσσα Python** και βιβλιοθήκες της, που μπορούν να χρησιμοποιηθούν κατά το δοκούν. Μόνο με συνεννόηση με τον εκάστοτε επιβλέποντα μπορεί να διαφοροποιηθεί η γλώσσα υλοποίησης (όπως το να γίνει η υλοποίηση σε MATLAB, R, Julia, κλπ.). Για όλα τα προτεινόμενα θέματα ισχύει ότι ο κώδικας της υλοποίησης θα πρέπει να παραδοθεί στον αντίστοιχο επιβλέποντα ως παραδοτέο, είτε με τη μορφή αρχείου ή αρχείων, είτε με κάποιο link στο cloud (π.χ. Google Colab, GitHub, κλπ.). Με βάση τις αναλυτικές οδηγίες που θα δίνονται τακτικά στο μάθημα, αλλά και στο e-class του μαθήματος, η διαδικασία αξιολόγησης των θεμάτων project είναι η ακόλουθη (ενδιάμεσα επικοινωνείτε ελεύθερα με τον επιβλέποντά σας μέσω e-mail, για πάσα καθοδήγηση και αρωγή).

Ενδιάμεση παρουσίαση. Καλείστε σε ένα ενδιάμεσο σημείο του εξαμήνου (θα οριστούν ημερομηνίες μέσα στο Νοέμβρη) να παρουσιάσετε κάποια πρόοδο της υλοποίησης, ενδεικτικά έως και 50%. Η παρουσίαση γίνεται χρήσει λογισμικού παρουσίασης και με ενδεχόμενη επίδειξη εκτέλεσης της υλοποίησης (demo), εντός το πολύ 20 λεπτών της ώρας, ενώπιον του επιβλέποντα και των συνεργατών του. Η φάση αυτή δεν αφορά μια επίσημη εξέταση - είναι όμως υποχρεωτική για τη λήψη προβιβάσιμου βαθμού στο μάθημα - μα αλληλεπίδραση με τον επιβλέποντα, παροχή βοήθειας και συμβουλών από αυτόν, και γενικότερο brainstorming για τη συνέχιση του project μέχρι και την τελική εξέταση. Θα ζητηθεί να έχει γίνει κατανοητό το πρόβλημα το οποίο θα αφορά το τηλεπικοινωνιακό (5G) κομμάτι, και όχι μόνο η μεθοδολογία (ειδικά όταν αυτή αφορά δεδομένα και AI), αλλά το ζήτημα που αυτή επιλύει και τα συμπεράσματα που εξάγονται σε επίπεδο τηλεπικοινωνιακής εφαρμογής.

Τελική εξέταση. Καλείστε σε τελικό σημείο του εξαμήνου (θα οριστούν ημερομηνίες μέσα στο Δεκέμβρη) να παρουσιάσετε όλη την υλοποίηση. Η παρουσίαση γίνεται χρήσει λογισμικού παρουσίασης και με ενδεχόμενη επίδειξη εκτέλεσης της υλοποίησης (demo), εντός το πολύ 20 λεπτών της ώρας, ενώπιον του επιβλέποντα και των συνεργατών του. Εδώ γίνεται επίσημη εξέταση, η φάση προφανώς και είναι υποχρεωτική, όπως άλλωστε και η παρουσίαση στο ενδιάμεσο στάδιο, και πραγματοποιούνται ερωτήσεις εξέτασης και αξιολόγησης της κατανόησης του προβλήματος που πραγματεύεται το project, και οι οποίες αφορούν τόσο τη θεωρία όσο και λεπτομέρειες υλοποίησης. Θα ζητηθεί να έχει γίνει κατανοητό το πρόβλημα που αφορά το τηλεπικοινωνιακό (5G) κομμάτι, και όχι μόνο η μεθοδολογία (ειδικά όταν αυτή αφορά δεδομένα και AI), αλλά το ζήτημα που αυτή επιλύει και τα συμπεράσματα που εξάγονται σε επίπεδο τηλεπικοινωνιακής εφαρμογής.

Κοντά στην περίοδο που θα αρχίζει η εξεταστική του χειμερινού εξαμήνου, θα υπάρχει και το **deadline** για την παράδοση και μιας αναφοράς (θα οριστεί ημερομηνία). Η **αναφορά** πρέπει να περιγράφει την όλη διαδικασία αντιμετώπισης του project λεπτομερειακά, με όλες τις μεθόδους, όλα τα αποτελέσματα, τα συμπεράσματα, και να είναι μέσα στις **10-20 σελίδες** κειμένου. Το τελικό παραδοτέο για προβιβάσιμο βαθμό θα αποτίθεται σε μορφή zip στο e-class όταν σας ζητηθεί, και θα πρέπει να περιέχει την τελική αναφορά, την τελική παρουσίαση (υποσύνολο της οποίας αποτελεί η ενδιάμεση), αλλά και τα αρχεία κώδικα (εναλλακτικά, και όπως λέμε πριν, το link όπου αποτίθεται όλος ο κώδικας σε ευδιάκριτο σημείο της αναφοράς ή/και της παρουσίασης).

- **Συμβουλή #1:** Επικοινωνείτε μέσω e-mail ενδιάμεσα με τον επιβλέποντά σας για πάσα καθοδήγηση.
- **Συμβουλή #2:** Δίνετε το παρόν σε όσες δυνατόν παρουσιάσεις μπορείτε, και όχι μόνο στις δικές σας.

1. Κλιμάκωση Ροής Βίντεο Σε Kubernetes

Οι σύγχρονες υπηρεσίες video streaming πρέπει να μπορούν να εξυπηρετούν μεταβαλλόμενο αριθμό χρηστών, διατηρώντας αποδεκτή απόδοση και αξιοποιώντας αποτελεσματικά τους διαθέσιμους υπολογιστικούς πόρους. Σε cloud-native περιβάλλοντα, το Kubernetes επιτρέπει την αυτοματοποιημένη ανάπτυξη, κλιμάκωση και κατανομή containerized εφαρμογών σε πολλαπλούς κόμβους. Στόχος της εργασίας είναι η ανάπτυξη μιας containerized υπηρεσίας video streaming και η πειραματική αξιολόγησή της σε multi-node Kubernetes cluster. Το workload δεν θα παράγεται από πραγματικές συσκευές ή από χρήστες που συνδέονται χειροκίνητα στην

11. Πρόβλεψη Downlink Bitrate (Throughput) Με Βάση Μετρικές Ποιότητας

Η διαθέσιμη ποιότητα σύνδεσης ενός χρήστη σε ένα κινητό δίκτυο μεταβάλλεται συνεχώς λόγω της κινητικότητας του χρήστη, των χαρακτηριστικών του ασύρματου καναλιού, της φόρτισης του δικτύου και άλλων παραγόντων. Η πρόβλεψη του μελλοντικού throughput μπορεί να επιτρέψει σε ένα δίκτυο να εντοπίζει έγκαιρα πιθανή υποβάθμιση της σύνδεσης και να λαμβάνει proactive αποφάσεις για τη διαχείριση των δικτυακών πόρων και την υποστήριξη των απαιτήσεων QoS. Στην εργασία αυτή θα χρησιμοποιηθούν πραγματικές μετρήσεις από κινητή συσκευή για να μελετηθεί η πρόβλεψη του downlink bitrate. Παρότι το διαθέσιμο dataset προέρχεται από LTE measurements, οι φοιτητές θα εξετάσουν πώς μια αντίστοιχη προσέγγιση μπορεί να αξιοποιηθεί σε σύγχρονα 5G δίκτυα για radio/network monitoring και proactive QoS management. Παρέχεται ένα σύνολο δεδομένων από κινητή συσκευή (κινητό τηλέφωνο) που “κατεβάζει” δεδομένα, συνδεδεμένη σε ασύρματο δίκτυο:

https://www.kaggle.com/datasets/aeryss/lte-dataset/data

Οι μεταβλητές περιλαμβάνουν τα downlink και uplink bitrates (ρυθμός μετάδοσης δεδομένων), δείκτες ποιότητας της σύνδεσης στο δίκτυο καθώς και δείκτες σχετικούς με την κίνηση της συσκευής. Η συχνότητα μέτρησης των δεδομένων (granularity) είναι 1s, και το dataset περιέχει μετρήσεις για ακίνητη συσκευή καθώς και κινούμενη συσκευή σε διάφορες συνθήκες (περπάτημα, αυτοκίνητο, τρένο, λεωφορείο).

Τα ζητούμενα είναι τα εξής:

1. Εξηγήστε την σημασία της πρόβλεψης του throughput (downlink bitrate) των συσκευών στα σύγχρονα δίκτυα 5G.
2. Εκτελέστε την απαραίτητη προεπεξεργασία των δεδομένων (αφαίρεση null τιμών, κανονικοποίηση κ.λπ.) καθώς και σύνδεση των διαφόρων traces για κάθε σενάριο κίνησης σε ένα ενιαίο σύνολο δεδομένων, το οποίο θα χωρίσετε σε train και test datasets επιλογής σας.
3. Εκπαιδεύστε ένα απλό μοντέλο μηχανικής μάθησης για παλινδρόμηση (regression) όπως π.χ. XGBoost regressor, για πρόβλεψη (forecasting) του downlink bitrate με βάση τις προηγούμενες τιμές των μεταβλητών με βάση τα training και testing datasets που έχετε επιλέξει. Δοκιμάστε διάφορες τιμές για το lookback window (πόσα προηγούμενα δείγματα δέχεται ως είσοδο το μοντέλο) και του prediction horizon (πόσα βήματα προβλέπει). Υπολογίστε κατάλληλες μετρικές για την αξιολόγηση του μοντέλου, όπως root mean squared error (RMSE), mean absolute error (MAE), mean absolute percentage error (MAPE). Αναλύστε τα αποτελέσματα.
4. Χρησιμοποιήστε τεχνική explainable AI (XAI) της επιλογής σας (π.χ. XGBoost interpreter, SHAP) για να εντοπίσετε ποιες μεταβλητές επηρεάζουν περισσότερο τις προβλέψεις του μοντέλου. Παρουσιάστε τα αποτελέσματα.
5. Εκπαιδεύστε ένα απλό μοντέλο deep learning για time series forecasting (π.χ. LSTM model) αρχιτεκτονικής της επιλογής σας που θα προβλέπει το downlink bitrate την επόμενη χρονική στιγμή, με βάση τις τιμές των μεταβλητών τις προηγούμενες χρονικές στιγμές (επιλέξτε πόσα προηγούμενα δείγματα θα χρησιμοποιείτε για την πρόβλεψη, π.χ. 64 δείγματα). Διαχειριστείτε το dataset κατάλληλα ώστε να δημιουργήσετε δεδομένα κατάλληλα για training και testing του μοντέλου (δημιουργείστε time-series windows). Υπολογίστε τις απαραίτητες μετρικές αξιολόγησης, παρουσιάστε τα αποτελέσματα και συγκρίνετε με το προηγούμενο μοντέλο.
6. Bonus- Πρόβλεψη με χρήση Foundation Models (Zero-shot & Fine-tuning): Χρησιμοποιήστε ένα σύγχρονο Foundation Model για χρονοσειρές (ενδεικτικά το IBM Granite Tiny Time Mixer.

https://github.com/ibm-granite/granite-tsfm) για την πρόβλεψη του downlink bitrate.

- Zero-shot Forecasting: Εφαρμόστε το προ-εκπαιδευμένο μοντέλο απευθείας στο test dataset (χωρίς επιπλέον εκπαίδευση) και υπολογίστε τις μετρικές.
- Εκτελέστε μια γρήγορη προσαρμογή (fine-tuning) του μοντέλου στο δικό σας training dataset για λίγες εποχές (epochs) και καταγράψτε τη βελτίωση στην ακρίβεια.
- Σύγκριση: Συγκρίνετε την απόδοση του Foundation Model με τα προηγούμενα μοντέλα (XGBoost και LSTM).

7. Με βάση τα αποτελέσματα της τεχνικής XAI ή άλλων τεχνικών της επιλογής σας, αφαιρέστε σταδιακά μεταβλητές από το training dataset, οι οποίες επηρεάζουν λιγότερο την πρόβλεψη των μοντέλων. Υπολογίστε τις μετρικές αξιολόγησης και δείξτε πως επηρεάζεται η απόδοση των μοντέλων αλλά και τα training και inference times.
8. 5G Proactive Network Management: Θεωρήστε ότι το μοντέλο forecasting χρησιμοποιείται από ένα 5G network management/control function για να προβλέψει την ποιότητα σύνδεσης ενός UE. Για διαφορετικά prediction horizons:
    - Υπολογίστε το prediction error,
    - Εξετάστε πόσο νωρίτερα μπορεί να εντοπιστεί πιθανή υποβάθμιση,
    - Εξηγήστε τι είδους proactive ενέργεια θα μπορούσε θεωρητικά να ληφθεί από το δίκτυο,
    - Αναλύστε το trade-off μεταξύ prediction accuracy και διαθέσιμου χρόνου για proactive network action, ανάμεσα στα διαφορετικά horizons που εξετάσατε.

Επιβλέπων: Παναγιώτης Μαράντης (pmaradis@isi.gr).

12. Uncertainty-Aware Intrusion Detection System (IDS) Για Δίκτυα Επόμενης Γενιάς (5G/6G)

Τα AI-based Intrusion Detection Systems μπορούν να επιτυγχάνουν υψηλή ακρίβεια στην αναγνώριση δικτυακών επιθέσεων. Ωστόσο, σε ένα πραγματικό δίκτυο δεν είναι αρκετό ένα σύστημα να παρέχει μόνο μία πρόβλεψη. Είναι επίσης σημαντικό να μπορεί να αναγνωρίζει περιπτώσεις στις οποίες η απόφασή του είναι αβέβαιη, ώστε οι αμφίβολες περιπτώσεις να μπορούν να εξεταστούν με διαφορετικό τρόπο. Η ανάγκη αυτή είναι ιδιαίτερα σημαντική σε 5G/6G δίκτυα, όπου ένα IDS μπορεί να πρέπει να επεξεργάζεται μεγάλο όγκο ετερογενούς δικτυακής κίνησης και οι λανθασμένες αποφάσεις μπορούν να οδηγήσουν είτε σε μη ανίχνευση επιθέσεων είτε σε μεγάλο αριθμό false alarms. Σε αυτή την εργασία, θα αναπτύξετε ένα αξιόπιστο Σύστημα Ανίχνευσης Εισβολών (Intrusion Detection System- IDS) χρησιμοποιώντας το σύνολο δεδομένων CICIoT2023 το οποίο περιέχει διάφορα είδη δικτυακών επιθέσεων (attack samples) αλλά και κανονικές ροές δικτύου (benign samples). Ακολουθούν πηγές για πρόσβαση στο dataset καθώς και η δημοσίευση με όλα τα απαραίτητα στοιχεία για την κατανόησή του:

https://www.unb.ca/cic/datasets/iotdataset-2023.html

https://www.kaggle.com/datasets/himadri07/ciciot2023

https://www.mdpi.com/1424-8220/23/13/5941

Στόχος είναι να ξεπεράσετε τις απλές προβλέψεις σημείου (point-predictions) και να μεταβείτε σε Προβλέψεις Συνόλων (Set Predictions) μέσω της Σύμμορφης Πρόβλεψης (Conformal Prediction- CP). Αυτό επιτρέπει στο σύστημα να αναγνωρίζει πότε "δεν είναι σίγουρο" για μια απόφαση, αυξάνοντας την αξιοπιστία του (Trustworthiness).

παράδειγμα, και την αρχιτεκτονική Real-MLP, βλέπε https://arxiv.org/abs/2407.04491- ιδανικά πρέπει να υλοποιηθούν και τα δύο, MLP και Real-MLP). Στη διάρκεια της όλης διαδικασίας πρέπει να γίνει tuning των hyperparameters που θα χρησιμοποιηθούν, και τις οποίες θα κρίνετε εσείς ποιες είναι (βλέπε π.χ. για την XGBoost: eta, gamma, max_depth, κλπ.), με 10-fold cross validation στο train set. Απαιτείται μαζί με την υλοποίηση των παραπάνω, μα και για όλα όσα ακολουθούν, η πλήρης θεωρητική κατανόηση των τεχνικών που εφαρμόζονται.

4. Η επεξηγησιμότητα (explainability) θα εφαρμοστεί με τη χρήση της τεχνικής SHAP. Παραδοσιακά, για την XGBoost υπάρχει έτοιμη μια προσαρμοσμένη εντολή για τη SHAP, ενώ γενικά για τα δενδροειδή μοντέλα εφαρμόζεται η TreeSHAP (δείτε https://shap.readthedocs.io/en/latest/generated/shap.TreeExplainer.html). Ομοίως (https://shap.readthedocs.io/en/latest/generated/shap.DeepExplainer.html), η DeepSHAP υπάρχει για τα deep learning μοντέλα. Με τη μέθοδο SHAP, παράγετε όσο το δυνατόν πιο πολλά σχετικά γραφήματα (visualizations), όπως waterfall, beeswarm, importance plots, κλπ. Η σημασία της μεθοδολογίας ποια είναι; Γνωρίζετε να ερμηνεύετε όλα τα αποτελέσματα των γραφημάτων; Αν με βάση τη σημαντικότητα κατά SHAP επιλέξουμε (υποσύνολο βέλτιστων) predictors, καταφέρνουμε καλύτερα αποτελέσματα πρόβλεψης; Τέλος, δοκιμάστε επιπλέον την παραλλαγή LightSHAP (https://lorentzen.ch/index.php/2025/10/15/introducing-lightshap/) για λόγους ταχύτητας, αλλά και την παραλλαγή SHAP-IQ (https://github.com/mmschlk/shapiq) για μελέτη των Shapley Interactions. Τι είναι και τι παρατηρείτε;

5. Οι αποδοτικότητες των κατηγοριοποιήσεων ζητείται να αποτιμηθούν με τη χρήση κατάλληλων μετρικών (% correctly classified instances- accuracy, precision, recall, F1-score, και ROC AUC- συμπεριλαμβάνοντας τη ROC καμπύλη). Δώστε ένα σύνολο από συγκριτικές αποτιμήσεις για όλα τα άνωθεν και σχολιάστε, τόσο ως προς την απόδοση όσο και για τους χρόνους, αλλά και σχετικά με την επεξηγηματικότητα.

   - Σχετικά με το statement του άρθρου στο https://arxiv.org/abs/2207.08815, επιβεβαιώνετε;

6. Παρέχετε για όλα τα αποτελέσματα την τηλεπικοινωνιακή τους φύσεως σημασία. Καταγράφοντας χρόνους εκτέλεσης στο training και στο inference, ποιο είναι το χρονικό overhead των μεθόδων επεξηγησιμότητας; Πώς φαντάζεστε την ενορχήστρωση ενός δικτύου 5G ή 6G που χρησιμοποιεί όλες τις μεθόδους αυτές, αλλά και ποια χαρακτηριστικά διαδραματίζουν ιδιαίτερο ρόλο στον Υπολογισμό Άκρου Πολλαπλής Πρόσβασης (και γιατί θεωρείτε);

Επιβλέπων: Γιάννης Λακουμέντας (lakoumen@upatras.gr).

Παράρτημα – Εκπαιδευτικό Υλικό

1. **Επεξήγηση της διαδικασίας κανονικοποίησης (normalization) των δεδομένων:**

   https://www.geeksforgeeks.org/what-is-data-normalization/

   https://www.digitalocean.com/community/tutorials/normalize-data-in-python

   Η κανονικοποίηση (normalization) είναι μια απαραίτητη τεχνική προεπεξεργασίας δεδομένων, όπου οι τιμές των δεδομένων προσαρμόζονται σε ένα προκαθορισμένο εύρος τιμών, συνήθως στο [0,1]. Η κανονικοποίηση είναι συνήθως απαραίτητη πριν την εισαγωγή των δεδομένων σε οποιοδήποτε μοντέλο μηχανικής μάθησης, καθώς εγγυάται ότι κάθε χαρακτηριστικό (feature) συνεισφέρει εξίσου, αποτρέποντας χαρακτηριστικά μεγαλύτερου μεγέθους από το να επισκιάσουν άλλα. Η υλοποίηση της τεχνικής μπορεί να γίνει πολύ απλά με χρήση της βιβλιοθήκης scikit-learn, όπως στις παραπάνω πηγές. Να σημειωθεί ότι μόνο τα δεδομένα που παίρνουν συνεχείς τιμές έχει νόημα να κανονικοποιηθούν, και όχι τα δεδομένα τύπου categorical variables (δηλαδή τιμές τύπου ΝΑΙ, ΟΧΙ κ.λπ.). Αυτού του τύπου δεδομένα τα χειριζόμαστε με την απλές τεχνικές όπως one-hot encoding και label encoding.

2. **Label encoding και One hot encoding για categorical μεταβλητές:**

https://www.statology.org/label-encoding-vs-one-hot-encoding/

https://www.statology.org/one-hot-encoding-in-python/

https://www.statology.org/label-encoding-in-python/

https://www.geeksforgeeks.org/ml-one-hot-encoding-of-datasets-in-python/

https://medium.com/data-folks-indonesia/powering-up-your-pandas-part-ii-label-encoding-and-one-hot-encoding-dac0fce045da

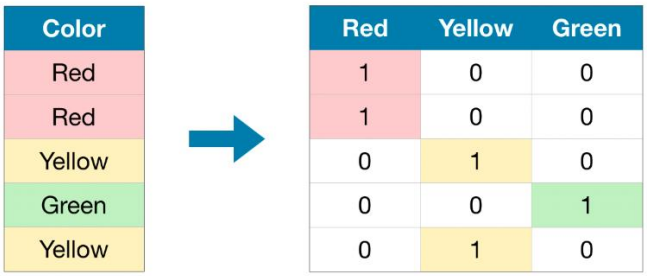
One hot encoding: Είναι τεχνική που χρησιμοποιείται για την αναπαράσταση κατηγορικών μεταβλητών ως δυαδικά διανύσματα. Στη μηχανική μάθηση, πολλοί αλγόριθμοι και μοντέλα απαιτούν αποκλειστικά αριθμητικά δεδομένα και οι κατηγορικές μεταβλητές (οι οποίες μπορούν να λάβουν ένα περιορισμένο, σταθερό σύνολο τιμών) πρέπει να μετατραπούν σε μια μορφή που μπορεί να χρησιμοποιηθεί εύκολα. Η απλή κωδικοποίηση είναι μια συνηθισμένη μέθοδος χειρισμού αυτής της μετατροπής. Ενδεικτικά βήματα είναι:

- Προσδιορισμός Κατηγορικής Μεταβλητής: Οι κατηγορικές μεταβλητές είναι εκείνες που μπορούν να λάβουν ένα περιορισμένο, σταθερό σύνολο τιμών. Για παράδειγμα, μια μεταβλητή "Χρώμα" με τιμές όπως "Κόκκινο", "Πράσινο" και "Μπλε".
- Δημιουργία δυαδικών διανυσμάτων: Για κάθε μοναδική τιμή στην κατηγορική μεταβλητή, δημιουργήστε ένα δυαδικό διάνυσμα μήκους ίσο με τον αριθμό των μοναδικών τιμών. Κάθε στοιχείο στο διάνυσμα αντιστοιχεί σε μια μοναδική κατηγορία και όλα τα στοιχεία ορίζονται στο 0 εκτός από αυτό που αντιστοιχεί στην πραγματική κατηγορία, το οποίο έχει οριστεί σε 1.

Παράδειγμα: Χρησιμοποιώντας μια μεταβλητή "Χρώμα":

Αρχικές τιμές: "Κόκκινο", "Πράσινο", "Μπλε"

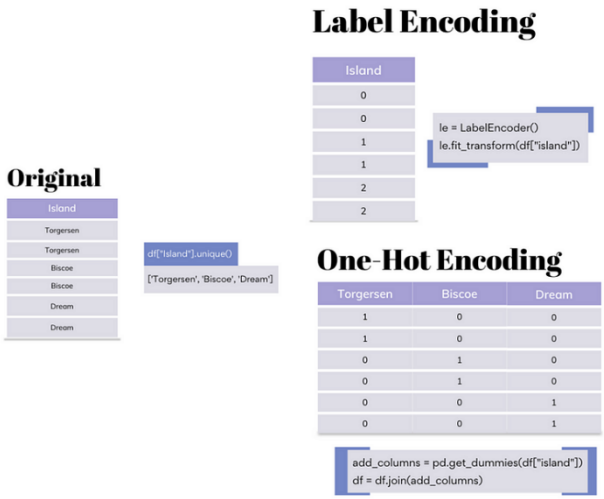
One-hot κωδικοποίηση: Κόκκινο: [1, 0, 0], Πράσινο: [0, 1, 0], Μπλε: [0, 0, 1]



Παράδειγμα One-hot κωδικοποίησης.

Label encoding: Το label encoding είναι μια άλλη τεχνική που χρησιμοποιείται στη μηχανική εκμάθηση για τη μετατροπή κατηγορικών μεταβλητών σε αριθμητική μορφή. Σε αντίθεση με την κωδικοποίηση one-hot, εκχωρεί έναν μοναδικό ακέραιο σε κάθε κατηγορία, μετατρέποντας ουσιαστικά τις κατηγορίες σε αριθμητικές ετικέτες. Δηλαδή:

Εκχωρήστε μοναδικό ακέραιο σε κάθε κατηγορία: Για κάθε μοναδική κατηγορία στη μεταβλητή κατηγορίας, αντιστοιχίστε μια μοναδική ακέραια ετικέτα. Οι ετικέτες συνήθως εκχωρούνται με αύξουσα σειρά με βάση τη σειρά εμφάνισης στο σύνολο δεδομένων.



Παράδειγμα υλοποίησης των δύο τεχνικών για την ίδια κατηγορική μεταβλητή με διακριτές ονομαστικές τιμές

Παράδειγμα: Θεωρήστε μια κατηγορική μεταβλητή "απόδοση" με τιμές "πολύ καλή", "καλή" και "μέτρια", οι ετικέτες τότε μέτρια: 0, καλή: 1, πολύ καλή: 2 ή μεταβλητή ‘χρώμα’ με τιμές ‘μπλε’, ‘κόκκινο’, ‘πράσινο’ και ετικέτες μπλε:0, κόκκινο:1, πράσινο:2.

Η τεχνική είναι συχνά κατάλληλη για κατηγορικές μεταβλητές η σειρά των οποίων έχει σημασία. Ωστόσο, θα πρέπει να χρησιμοποιείται με προσοχή για ονομαστικές μεταβλητές (κατηγορίες χωρίς εγγενή σειρά), καθώς οι αριθμητικές ετικέτες ενδέχεται να εισαγάγουν ακούσια μια λανθασμένη αίσθηση τακτικότητας στο μοντέλο (π.χ. ότι η τιμή ‘μπλε’ με ετικέτα 0 είναι μικρότερη από την τιμή ‘κόκκινο’ με ετικέτα 1, κάτι που προφανώς δεν ισχύει).

Πλεονεκτήματα: Απλότητα και μείωση διαστάσεων δεδομένων σε σύγκριση με την κωδικοποίηση One-hot.

Μειονεκτήματα: Μπορεί να μην είναι κατάλληλη για ονομαστικές μεταβλητές, όπως δείξαμε παραπάνω.

3. **Διαχωρισμός δεδομένων σε training set (δεδομένα εκπαίδευσης) και test set (δεδομένα δοκιμών):** Στη μηχανική μάθηση, υπάρχει η πιθανότητα ένα μοντέλο να έχει πολύ καλά αποτελέσματα για ένα συγκεκριμένο σύνολο δεδομένων αλλά να μην δίνει καλά αποτελέσματα για ένα άλλο σύνολο παρόμοιων δεδομένων. Αυτό συνήθως σημαίνει ότι το μοντέλο έχει μάθει μόνο τα δεδομένα στα οποία εκπαιδεύτηκε και δεν μπορεί να γενικεύσει σε νέα δεδομένα. Το φαινόμενο αυτό ονομάζεται υπερεκπαίδευση (overfitting). Είναι συνεπώς σημαντικό να αξιολογηθεί πόσο καλά ένα μοντέλο γενικεύεται σε δεδομένα που δεν έχει ξανασυναντήσει. Η διαδικασία διαχωρισμού ενός συνόλου δεδομένων σε δύο υποσύνολα (εκπαίδευσης και δοκιμών) διευκολύνει αυτήν την αξιολόγηση.

   Το σετ εκπαίδευσης είναι το τμήμα του συνόλου δεδομένων που χρησιμοποιείται για την εκπαίδευση ή την προσαρμογή του μοντέλου μηχανικής εκμάθησης. Το μοντέλο μαθαίνει μοτίβα, σχέσεις και χαρακτηριστικά από αυτό το υποσύνολο. Τυπικά, το σύνολο εκπαίδευσης περιλαμβάνει ένα σημαντικό ποσοστό του συνολικού συνόλου δεδομένων, συχνά γύρω στο 70-80%.

   Το σύνολο δοκιμών προορίζεται για την αξιολόγηση της απόδοσης του εκπαιδευμένου μοντέλου σε νέα δεδομένα. Το μοντέλο δεν έχει δει τα παραδείγματα στο σύνολο δοκιμών κατά τη διάρκεια της εκπαίδευσης, επιτρέποντας μια ρεαλιστική αξιολόγηση των δυνατοτήτων γενίκευσής του. Το σύνολο δοκιμών διατηρείται χωριστό μέχρι να εκπαιδευτεί το μοντέλο.

   Ο λόγος διαχωρισμού καθορίζει την αναλογία των δεδομένων που κατανέμονται στο σετ εκπαίδευσης και στο σετ δοκιμής. Συνηθισμένες αναλογίες είναι 70-30, 80-20 ή 90-10, ανάλογα με το μέγεθος του συνόλου δεδομένων και τις απαιτήσεις του προβλήματος.

   Παράδειγμα κώδικα σε python:

```
from sklearn.model_selection import train_test_split

# X: Features, y: Labels

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2)
```

όπου X είναι το σύνολο των δεδομένων πριν τον διαχωρισμό (χωρίς να περιέχουν τη μεταβλητή στόχο y που θέλουμε να προβλέψουμε), y είναι η μεταβλητή στόχος και test_size είναι το ποσοστό των δεδομένων που θα κατανεμηθούν στο test set.

Πλήρες παράδειγμα: https://builtin.com/data-science/train-test-split

4. Classification (κατηγοριοποίηση)- supervised learning:

Η κατηγοριοποίηση είναι ένας τύπος εποπτευόμενης (supervised) μηχανικής μάθησης όπου ο στόχος είναι να ανατεθούν προκαθορισμένες ετικέτες ή κατηγορίες σε δεδομένα εισόδου με βάση τα χαρακτηριστικά τους (supervised learning είναι οι περιπτώσεις όπου υπάρχουν ετικέτες για τα δεδομένα και γνωρίζουμε σε ποια ετικέτα ανήκει κάθε δείγμα από το σύνολο των δεδομένων). Με άλλα λόγια, ο αλγόριθμος μαθαίνει έναν τρόπο χαρτογράφησης από τα χαρακτηριστικά της εισόδου στις ετικέτες (labels) εξόδου με εκπαίδευση σε ένα σύνολο δεδομένων. Ο κύριος στόχος της κατηγοριοποίησης είναι να γενικεύσει αυτήν την αντιστοίχιση για να κάνει ακριβείς προβλέψεις σε νέα παραδείγματα.

Δεδομένα Εισόδου: Τα δεδομένα εισόδου αποτελούνται από παραδείγματα ή περιπτώσεις, καθένα από τα οποία περιγράφεται από ένα σύνολο χαρακτηριστικών. Αυτά τα χαρακτηριστικά αποτελούν την είσοδο του αλγορίθμου.

Ετικέτες ή Κατηγορίες (labels): Κάθε δείγμα στο σύνολο δεδομένων συσχετίζεται με μια προκαθορισμένη ετικέτα ή κατηγορία. Οι κατηγορίες αντιπροσωπεύουν τις διάφορες κατηγορίες ή αποτελέσματα που ο ταξινομητής προσπαθεί να προβλέψει.

Σύνολο Δεδομένων Εκπαίδευσης: Το σύνολο δεδομένων εκπαίδευσης είναι ένα σύνολο δεδομένων που χρησιμοποιείται για την εκπαίδευση του μοντέλου κατηγοριοποίησης. Σημείωση: Συνίσταται για κάθε κατηγορία (label) να χρησιμοποιηθεί περίπου ίδιος αριθμός δειγμάτων από την κατηγορία (π.χ. 1000 δείγματα με label 0, 1000 δείγματα με label 1, 1000 δείγματα με label 2 κοκ) καθώς αν έχουμε άνισες κατηγορίες (imbalanced classes)

Εκπαίδευση του Μοντέλου (training phase): Κατά τη διάρκεια της φάσης της εκπαίδευσης, ο αλγόριθμος κατηγοριοποίησης μαθαίνει τις σχέσεις μεταξύ των χαρακτηριστικών της εισόδου και των αντίστοιχων ετικετών από τα δεδομένα εκπαίδευσης.

Δοκιμή (testing phase): Μετά την εκπαίδευση, το μοντέλο δοκιμάζεται στο σύνολο δοκιμής. Αυτό το βήμα αξιολογεί πόσο καλά γενικεύει το μοντέλο σε νέα δεδομένα.

Προβλέψεις (predictions): Το μοντέλο προβλέπει την ετικέτα για κάθε περίπτωση στο σύνολο δοκιμής.

Μετρικές Αξιολόγησης: Τα μοντέλα κατηγοριοποίησης αξιολογούνται χρησιμοποιώντας διάφορες μετρικές, ανάλογα με τη φύση του προβλήματος. Συνήθεις μετρικές περιλαμβάνουν την ακρίβεια (accuracy), το F1 score και τον πίνακα σύγχυσης (confusion matrix).

Τύποι Αλγορίθμων Κατηγοριοποίησης: Συνήθεις αλγόριθμοι περιλαμβάνουν τη λογιστική παλινδρόμηση (logistic regression), τα δέντρα απόφασης (decision trees), τα τυχαία δάση (random forest), τις μηχανές διανυσμάτων υποστήριξης (SVM), τους k-κοντινότερους γείτονες (KNN) και τα νευρωνικά δίκτυα.

Δυαδική (binary) και Πολυκατηγορική (multiclass or multilabel) κατηγοριοποίηση: Στη δυαδική κατηγοριοποίηση, η εργασία επικεντρώνεται στη διάκριση μεταξύ δύο μόνο κατηγοριών. Στην πολυκατηγορική κατηγοριοποίηση, υπάρχουν περισσότερες από δύο κατηγορίες, και το μοντέλο πρέπει να

αναθέτει κάθε περίπτωση σε μία από αυτές τις κατηγορίες (π.χ., κατηγοριοποίηση εικόνων σε κατηγορίες όπως γάτα, σκύλος, κ.λπ.).

Η κατηγοριοποίηση είναι μια θεμελιώδης και ευρέως χρησιμοποιούμενη εργασία στη μηχανική μάθηση, εφαρμόζεται σε διάφορους τομείς όπως η αναγνώριση εικόνων, η ταξινόμηση κειμένου, η ιατρική διάγνωση και πολλοί άλλοι. Η επιλογή του κατάλληλου αλγορίθμου εξαρτάται από τα χαρακτηριστικά των δεδομένων και τις ειδικές απαιτήσεις του προβλήματος.

Ενδεικτικά Παραδείγματα:

Logistic Regression: https://www.educative.io/blog/machine-learning-classification-models-python

K-nearest-neighbors: https://www.tutorialspoint.com/machine_learning_with_python/machine_learning_with_python_knn_algorithm_finding_nearest_neighbors.htm

Binary neural network classifier with Keras: https://machinelearningmastery.com/binary-classification-tutorial-with-the-keras-deep-learning-library/

Multiclass neural network classifier with Keras: https://machinelearningmastery.com/multi-class-classification-tutorial-keras-deep-learning-library/

5. Εντοπισμός ανωμαλιών (anomaly or outlier detection) – (unsupervised learning):

Η ανίχνευση ακραίων τιμών, γνωστή επίσης ως ανίχνευση ανωμαλιών, είναι μια διαδικασία στην μηχανική μάθηση που περιλαμβάνει τον εντοπισμό παρατηρήσεων/δειγμάτων που αποκλίνουν σημαντικά από την πλειοψηφία των δεδομένων. Η ανίχνευση ακραίων τιμών είναι κρίσιμη σε διάφορους τομείς, όπως η ανίχνευση απάτης, ο έλεγχος ποιότητας, επιθέσεις σε δίκτυα κ.λπ.

Ορισμός των Ακραίων Τιμών: Οι ακραίες τιμές είναι σημεία δεδομένων που αποκλίνουν σημαντικά από το πρότυπο του συνόλου δεδομένων. Μπορεί να πρόκειται για τιμές που είναι ασυνήθιστα υψηλές ή χαμηλές σε σχέση με την πλειονότητα των δεδομένων.

Μέθοδοι για την Ανίχνευση Ακραίων Τιμών: Υπάρχουν διάφορες μέθοδοι μηχανικής μάθησης για την ανίχνευση ακραίων τιμών, και η επιλογή εξαρτάται συχνά από τη φύση των δεδομένων και τις συγκεκριμένες απαιτήσεις του προβλήματος. Αυτές οι τεχνικές αφορούν unsupervised learning, όπου δεν εκμεταλλευόμαστε εξαρχής labels στα δεδομένα αλλά το μοντέλο μαθαίνει να διαχωρίζει μόνο του τα δεδομένα σε φυσιολογικά και outliers. Το One-Class SVM, το Isolation forest και οι αυτοκωδικοποιητές (autoencoders) είναι παραδείγματα μοντέλων που μπορούν να μάθουν την κανονική συμπεριφορά των δεδομένων και να αναγνωρίσουν παρατηρήσεις που αποκλίνουν σημαντικά από αυτό. Να σημειωθεί πως στα περισσότερα προβλήματα το ποσοστό των ανωμαλιών είναι πολύ μικρό σε σχέση με το σύνολο των δεδομένων (ενδεικτικά συνήθως κάτω από 10%).

Αξιολόγηση της Ανίχνευσης Ακραίων Τιμών: Η απόδοση των μεθόδων ανίχνευσης ακραίων τιμών αξιολογείται συχνά με βάση μετρικές όπως precision, recall και F1 score. Η αποτελεσματικότητα της προσέγγισης εξαρτάται από την ικανότητά της να ανιχνεύει σωστά τις ακραίες τιμές ενώ περιορίζει τις ψευδείς θετικές.

Anomaly Detection with Isolation Forest: https://medium.com/mlearning-ai/unsupervised-outlier-detection-with-isolation-forest-eab398c593b2

6. Τεχνικές και αλγόριθμοι για eXplainable AI (XAI):

Η Επεξηγήσιμη Τεχνητή Νοημοσύνη (XAI) περιλαμβάνει τεχνικές και μεθόδους που καθιστούν τα μοντέλα μηχανικής μάθησης πιο διαφανή και κατανοητά για τους ανθρώπους. Η XAI βοηθά τους χρήστες να κατανοήσουν γιατί ένα μοντέλο έκανε μια συγκεκριμένη πρόβλεψη, να εντοπίσουν πιθανή μεροληψία

(bias) και να διασφαλίσουν τη συμμόρφωση με κανονισμούς σε ευαίσθητους τομείς όπως η υγεία, τα χρηματοοικονομικά και η επιβολή του νόμου. Οι εξηγήσεις σημαντικότητας χαρακτηριστικών (feature importance explanations) προσδιορίζουν ποια χαρακτηριστικά εισόδου (input features) επηρεάζουν περισσότερο τις προβλέψεις ενός μοντέλου. Τεχνικές όπως το SHAP και το LIME ποσοτικοποιούν και οπτικοποιούν αυτές τις επιρροές, διευκολύνοντας την κατανόηση και τη βελτίωση των μοντέλων μηχανικής μάθησης:

SHAP: Ο αλγόριθμος SHAP αποδίδει βαθμολογίες σημαντικότητας στις μεταβλητές εισόδου, υπολογίζοντας τη συνεισφορά κάθε χαρακτηριστικού στην πρόβλεψη ενός μοντέλου μέσω των τιμών Shapley. Παρέχει τόσο global (συνολική συμπεριφορά του μοντέλου) όσο και local (ερμηνεία μεμονωμένων προβλέψεων) εξηγήσεις και χρησιμοποιείται ευρέως για την ερμηνεία πολύπλοκων μοντέλων, όπως βαθιά νευρωνικά δίκτυα και gradient boosting (https://shap.readthedocs.io/en/latest/).

LIME: Προσεγγίζει τοπικά τη λειτουργία του μοντέλου που θέλουμε να εξηγήσουμε, δημιουργώντας ένα απλοποιημένο αντιπροσωπευτικό μοντέλο (π.χ. γραμμική παλινδρόμηση) γύρω από μια συγκεκριμένη πρόβλεψη. Αλλάζει ελαφρώς τα δεδομένα εισόδου και παρακολουθεί τις αλλαγές στις προβλέψεις για να προσδιορίσει τη σημαντικότητα των χαρακτηριστικών (https://lime-ml.readthedocs.io/en/latest/).

7. Docker και Kubernetes, χρήσιμα links:

https://www.docker.com/blog/how-to-set-up-a-kubernetes-cluster-on-docker-desktop/

https://kind.sigs.k8s.io

https://dev.to/olymahmud/running-a-kubernetes-cluster-with-k3s-30lo

https://medium.com/@amareswer/deploy-llms-on-kubernetes-complete-guide-with-examples-4fbd04d38d40

https://www.perfectscale.io/blog/llms-without-gpus

https://kubernetes.io/docs/concepts/workloads/autoscaling/horizontal-pod-autoscale/

https://spacelift.io/blog/kubernetes-hpa-horizontal-pod-autoscaler

https://dl.acm.org/doi/10.1145/3297858.3304013